

УТВЕРЖДЁН
RU.17701729.05-09 81 04-1

Инв. № подл	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

**ИНТЕЛЛЕКТУАЛЬНЫЙ АССИСТЕНТ ДЛЯ ОБРАЗОВАТЕЛЬНЫХ
УЧРЕЖДЕНИЙ**
Пояснительная записка
RU.17701729.05.09 81 04-1
Листов 28

СОДЕРЖАНИЕ

Оглавление

Введение	3
Наименование программы.....	3
Документ, на основании которого ведётся разработка	3
Назначение и область применения.....	4
Назначение программы.....	4
Краткая характеристика области применения	4
Работа, выполненная в роли тимлида	5
Архитектура приложения	5
Технологический стек	6
API и RAG	7
Telegram-бот	7
Клиенты и интерфейсы	8
Модель данных.....	8
Потоки данных	9
Запуск и окружения	9
Безопасность.....	10
Сбор данных. Работа, выполненная в роли DevOps.....	10
Сбор данных	10
DevOps	10
Источники, использованные при разработке	26
Список терминов.....	27

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1 Наименование программы

Наименование темы разработки: Интеллектуальный ассистент для образовательных учреждений.

Наименование темы разработки на английском языке: Intelligent Assistant for Educational Institutions.

Web-версия расположена на домене <https://assistant-about-hse.ru/>. На сайте можно авторизоваться под учетной записью test:testtest

Telegram-версия @your_assistant_about_HSE_bot, не требует дополнительной авторизации.

1.2 Документ, на основании которого ведётся разработка

Основанием для разработки является учебный план бакалавриата по направлению «Программная инженерия» и утвержденная академическим руководителем тема курсового проекта.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

2. НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ

2.1. Назначение программы

2.1.1 Функциональное назначение

Во время обучения в Высшей Школе Экономики у любого из студентов возникает большое количество вопросов на огромное количество тем. Вариантов найти ответы на эти вопросы множество – от официального сайта университета до чата с одноклассником или куратором. Но никакой из одноклассников не сможет дать ответы на все вопросы, а искать информацию на сайте может быть неудобно в связи с огромным количеством статей на нем, децентрализацией информации по разным разделам, а иногда и доменам, и простой непопулярностью поиска нужной информации на сайтах. Для решения проблемы с трудностями получения оперативного ответа на свои вопросы по обучению мы предлагаем воспользоваться нашим продуктом – ИИ ассистентом, представленном в формате telegram-бота и web-сайта.

2.1.2 Эксплуатационное назначение

Сервис «Интеллектуальный ассистент для образовательных учреждений» предназначен для индивидуального использования с персональных компьютеров, ноутбуков или мобильных устройств в целях получения оперативного ответа на вопросы по теме обучения во ВШЭ. Сервис рассчитан на использование студентами во время обучения и ориентирован на оперативные ответы, опирающиеся на добавленную документацию. Сервис может быть персонализирован под любое учебное учреждение изменением набора используемых для ответа документов. Целевой аудиторией являются обучающиеся на бакалавриате и магистратуре Высшей Школы Экономики.

2.2 Краткая характеристика области применения

Сервис «Интеллектуальный ассистент для образовательных учреждений» предназначен для индивидуального использования пользователями с целью получения оперативной консультации по вопросам обучения.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3. РАБОТА, ВЫПОЛНЕННАЯ В РОЛИ ТИМЛИДА

Постановка задачи

Обеспечить команду разработчиков понятным алгоритмом выполнения поставленной задачи, включая архитектуру, план работ и ревью кода во избежание ошибок и проблем с точки зрения безопасности.

3.1. Архитектура приложения:

Основными рантайм-компонентами являются:

- src/server – FastAPI-приложение (RAG API, web-auth, web UI, метрики).
- src/bot – Telegram-бот на aiogram, работающий как клиент к API сервера.
- src/client – Streamlit-клиент для интерактивной работы.
- data_and_documents – набор документов для индексации в векторное хранилище.

Для лучшего понимания предмета разработки была создана следующая схема архитектуры сервиса:




Рисунок 1, основные компоненты сервиса

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

На основе представленной выше архитектуры с недельными спринтами, заканчивающимися ревью и правками, был реализован «Ассистент» со следующей структурой:

3.1.1. Структура репозитория

Ключевые директории верхнего уровня:

src/server – API и бизнес-логика RAG + web-часть.

src/bot – Telegram integration, преобразование пользовательского ввода.

src/client – Streamlit приложение.

tests – автотесты.

deployment/production – production compose + env rendering.

security – security-конфиги и политики сканирования.

template – jobs для GitLab CI.

data_and_documents – документы, составляющие базу для ответа.

3.2. Технологический стек

3.2.1. Backend и API

Python 3.12

FastAPI, Starlette, Uvicorn

Pydantic для схем запросов/ответов

slowapi для rate limiting

3.2.2. AI/RAG

LangChain

Ollama (LLM-инференс)

Chroma (vector store)

HuggingFaceEmbeddings (эмбеддинги)

pypdf, pytesseract, Pillow для извлечения текста из документов

3.2.3. Bot и клиенты

aiogram 3 для Telegram-бота

aiohttp/httpx (API вызовы, в зависимости от модуля)

Streamlit для web-клиента

Jinja-шаблоны для встроенного web UI

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

3.2.4. Данные и ORM

SQLAlchemy async ORM
PostgreSQL в Docker-сценариях
SQLite в локальных/встроенных сценариях

3.2.5. DevOps и качество

Docker , Docker Compose
pytest ruff , black , isort , pre-commit
Security tooling: gitleaks , semgrep , trivy , gype , syft , hadolint , checkov
GitLab CI/CD

3.3. API и RAG

3.3.1. Основные функции

Прием запросов (/ask , web routes, health/metrics).
Проверка авторизации (API key для API, cookie-сессии для web).
Контроль частоты запросов (rate limits).
Сбор контекста диалога и вызов RAG pipeline.
Fallback-механика при timeout/ошибках генерации.

3.3.2. Ключевые модули

src/server/app/main.py – точки входа и маршруты.
src/server/app/rag.py – retrieval+generation orchestration.
src/server/app/vector.py – векторное хранилище и retriever.
src/server/app/index_documents.py – индексация документного корпуса.
src/server/app/auth_models.py , auth_crud.py , auth_database.py – web-auth и сессии.
src/server/app/conversation_memory.py – память сообщений по сессии

3.4. Telegram-бот

3.4.1. Основные функции

Обработка входящих сообщений Telegram.
Преобразование контента для запроса.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Вызов серверного /ask endpoint.
Форматирование ответа пользователю.
Сохранение истории запросов в bot-таблицы.

3.4.2. Ключевые модули

src/bot/bot.py – запуск polling.
src/bot/handlers/common.py – OCR и PDF parsing.
src/bot/api_client.py – клиент к серверному API.
src/bot/service.py – оркестрация bot-side логики.
src/bot/core/models.py , crud.py , database.py – bot persistence.

3.5. Клиенты и интерфейсы

3.5.1. Основные функции

Поддержка двух пользовательских каналов: Telegram-бот и browser интерфейс.

3.5.2. Ключевые модули

src/client/app/streamlit_app.py – Streamlit фронт.
src/server/templates/index.html – встроенный web UI.

3.6. Модель данных

3.6.1. Web auth и memory

WebUser – учетная запись web-пользователя (username, password hash, поли).
WebSession – cookie-сессии (token hash, expiry, revoke status).
WebInvite – инвайты для регистрации (creator, consumer, expires).
ConversationMemoryMessage – история сообщений для session key.

3.6.2. Bot данные

User – Telegram user (telegram_id , username, first_seen).
Request – пользовательский запрос и ответ системы (content_type ,
raw_content , ai_response , timestamps).

3.6.3. Векторные данные

Коллекции чанков документов в Chroma.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Метаданные: source , title , page , chunk_id , indexed_at и прочее.

3.7. Потоки данных

3.7.1. Telegram to RAG to Telegram

1. Пользователь отправляет контент в Telegram.
2. Бот извлекает текст или берет исходный.
3. Бот отправляет запрос на /ask .
4. Сервер поднимает память диалога и выполняет retrieval.
5. LLM генерирует ответ; при ошибке используется fallback.
6. Ответ возвращается боту и отправляется пользователю.
7. История сохраняется в bot DB.

3.7.2. Индексация документов

1. Документы читаются из data_and_documents.
2. Текст разбивается на чанки.
3. Для чанков вычисляются эмбединги.
4. Данные сохраняются в Chroma persistent storage.

3.8. Запуск и окружения

3.8.1. Локальный запуск

1. Инициализировать окружение через uv.
2. Заполнить .env на основе .env.example .
3. Выполнить индексацию документов.
4. Запустить:
API (uvicorn src.server.app.main:app --reload)
Streamlit (streamlit run src/client/app/streamlit_app.py)
Bot (python -m src.bot.bot

3.8.2. Docker Compose запуск

docker-compose.yaml поднимает сервисы db , server , bot , client .
Есть healthcheck endpoints и зависимости по готовности.
Для production доступен отдельный compose в

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

deployment/production/compose.yaml

3.8.3. GitLab запуск

При пуше репозитория на GitLab автоматически создадутся пайплайны.

Все требуемые переменные следует добавить в переменные GitLab CI.

После регистрации раннера GitLab появляется возможность запустить пайплайны.

Автоматически отработают Check и Build, после чего следует вручную запустить Deploy to production.

3.9. Безопасность

В проекте реализованы следующие меры безопасности:

API key защита для API-эндпоинтов.

Сессии web-интерфейса на cookie (HttpOnly , SameSite , Secure при HTTPS).

Rate limiting на чувствительных endpoint'ах.

CORS allowlist.

Секреты через env-переменные.

Docker hardening: ограничения привилегий, seccomp, pids limits.

4. СБОР ДАННЫХ. РАБОТА, ВЫПОЛНЕННАЯ В РОЛИ DEVOPS.

4.1. Сбор данных

Документы, использующиеся RAG архитектурой собраны с официальных сайтов образовательного учреждения. Они помещены в директорию data_and_documents. Допустимыми форматами являются pdf и docx. Сбор данных осуществлялся вручную и посредством простейших парсеров. На момент публикации работы собрано около 1000 документов.

4.2. DevOps

Ассистент имеет два варианта, доступных для пользователя:

Web-версию, расположенную на домене <https://assistant-about-hse.ru/>. На сайте можно

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

авторизоваться под учетной записью test:testtest

Telegram-версию @your_assistant_about_HSE_bot, не требующую дополнительной авторизации.

4.2.1. GitLab, CI/CD, Deploy

Деплой сервиса осуществляется по средствам настроенного CI/CD на сайте GitLab, хостом которого, а также раннеров, является личная виртуальная машина. GitLab доступен по мере надобности по адресу <https://hse-bot-gitlab.msk.ru/>. Сам сервис развернут на другой личной виртуальной машине. Деплой с помощью GitLab CI обеспечивает возможность публикации новой версии сервиса одной кнопкой, без каких-либо мануальных действий, а так же позволяет обновить ассистента без даунтайма.

4.2.2. GitLab

GitLab по адресу <https://hse-bot-gitlab.msk.ru/> является селф-хост сервисом и, являясь опен-сорс продуктом, поднят в Docker. Домен приобретен, для его связи с поднятым на VM GitLab добавлена А-запись в DNS. Раннер, использующийся пайплайнами, так же зарегистрирован на этой виртуальной машине.

Тип	Значения
А	212.111.86.242

Рисунок 2, А-запись с IP VM

4.2.3. CI/CD

CI/CD реализован в виде пайплайна, имеющего следующие jobs: check и build, запускающиеся автоматически при коммите, и deploy-to-production, bot-start-production, bot-stop-production, требующие мануального запуска.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата




Рисунок 3, успешно выполненный пайплайн

Для обеспечения работоспособности пайплайнов, требуется зарегистрировать раннер, а также добавить необходимые переменные в GitLab.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Project variables

Variables can be accidentally exposed in a job log, or maliciously sent to a third party server. The masked variable feature can help reduce the risk of accidentally exposing variable values, but is not a guaranteed method to prevent malicious users from accessing variables. [How can I make my variables more secure?](#)

CI/CD Variables </> 19			Reveal values	Add variable
Key ↑	Value	Environments	Actions	
API_KEY Protected Masked	*****	All (default)		
BOT_TOKEN Protected Masked	*****	All (default)		
CI_REGISTRY Protected Masked	*****	All (default)		
CI_REGISTRY_IMAGE Protected Masked	*****	All (default)		
CI_REGISTRY_PASSWORD Protected Masked	*****	All (default)		
CI_REGISTRY_USER Protected	*****	All (default)		
DATABASE_URL Protected Masked	*****	All (default)		
LLM_MODEL Protected Masked	*****	All (default)		
LLM_TIMEOUT_SECONDS Protected Expanded	*****	All (default)		
POSTGRES_DB Protected Masked	*****	All (default)		
POSTGRES_PASSWORD Protected Masked	*****	All (default)		
POSTGRES_USER Protected Masked	*****	All (default)		
RAG_TOP_K Protected	*****	All (default)		
RAG_TOTAL_TIMEOUT_SECOND Protected Expanded	*****	All (default)		
SERVER_PUBLISH_PORT Protected	*****	All (default)		
SSH_HOST Protected Masked	*****	All (default)		
SSH_PRIVATE_KEY File Protected	*****	All (default)		
SSH_USER Protected	*****	All (default)		
WEB_BOOTSTRAP_ADMIN_TOKEN Protected Masked	*****	All (default)		

Рисунок 4, переменные GitLab

4.2.4. Ассистент

Сервис «Ассистент» хостится на еще одной виртуальной машине. Домен приобретен, для его связи с поднятым на ВМ «Ассистентом» добавлена А-запись в DNS.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Тип	Значения
A	84.201.148.52

Рисунок 5, А-запись с IP VM

После деплоя сервис не требует каких-либо мануальных действий, но при смене модели LLM на VM с «Ассистентом» следует выполнить команду `ollama pull <LLM_MODEL>`. Редеплой новой версии не вызывает остановки уже поднятого сервиса, интеграция проходит незаметно для пользователя.

4.2.5. HTTPS

Защищенное HTTPS соединение обеспечивается сертификатами, выданными сервисом Let’s Encrypt.

4.2.6. Общая картина взаимодействия машин




Рисунок 6, схема взаимодействия

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

4.2.7. Выбор модели LLM

После успешного деплоя нужно выбрать модель LLM, которая будет оптимальна по соотношению времени и качества ответа на конкретной машине.

Для этого в настройках CI/CD в секции Variables устанавливаем значением переменной LLM_MODEL интересующую нас в конкретном эксперименте.




Рисунок 7, значение переменной LLM_MODEL

Для проведения эксперимента были выбраны четырнадцать вопросов:

1. Кто ректор?
2. Что такое академический отпуск и почему его можно взять?
3. Какие документы нужно нести в военкомат для отсрочки?
4. Как пересдать экзамен, пропущенный по уважительной причине?
5. Какие уважительные причины бывают?

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

6. Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?
7. Что делать если не сдал экзамен?
8. Что такое летняя практика?
9. Что такое электронный студенческий билет?
10. Где электронный студенческий билет доступен?
11. Что такое КУД?
12. Где найти расписание?
13. Что такое независимый экзамен и какие они бывают?
14. Какие документы нужны первокурснику для поступления?

По следующим критериям по трехбалльной шкале:

1. Accuracy (точность)

Правильный ли ответ

- 1 – неправильно
- 2 – частично
- 3 – правильно

2. Relevance (релевантность)

Ответ на тот ли вопрос

- 1 – мимо
- 2 – частично
- 3 – в тему

3. Completeness (полнота)

Насколько раскрыта тема

- 1 – мало

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

- 2 – нормально
- 3 – подробно

4. Hallucinations (галлюцинации)

Есть ли выдумка

- 1 – много
- 2 – немного
- 3 – нет

5. Время ответа в секундах в миллисекундах

Для сравнения были выбраны следующие модели LLM:

- 1. qwen2.5:3b
- 2. llama3.2:3b
- 3. tinyllama
- 4. mistral:7b
- 5. qwen2.5:7b
- 6. gemma2:2b
- 7. phi3:3.8b
- 8. llama3.1:8b

Далее приведены результаты испытаний:

Для модели qwen2.5:3b

	Точность	Релевантность	Полнота	Галлюцинации	Время ответа, мс
Изм.	Лист	№ докум.	Подп.	Дата	
RU.17701729.05.09 81 04-1					
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата	

Кто ректор?	3	3	3	1	277 71
Что такое академический отпуск и почему его можно взять?	3	3	2	1	264 52
Какие документы нужно нести в военкомат для отсрочки?	3	3	3	1	295 91
Как происходит пересдача экзамена по уважительной причине?	2	2	3	2	401 71
Какие уважительные причины бывают?	2	3	2	2	311 49
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	2	3	3	2	408 55
Что делать если не сдал экзамен?	3	3	3	1	350 40
Что такое летняя практика?	2	3	2	1	311 95
Что такое электронный студенческий билет?	3	3	3	1	318 45
Где электронный студенческий билет доступен?	3	3	3	1	327 37
Что такое КУД?	1	1	2	1	311 29
Где найти расписание?	2	3	2	1	261 55
Что такое независимый экзамен и какие они бывают?	2	3	3	1	371 94
Какие документы нужны первокурснику для поступления?	3	3	2	1	398 39
Среднее значение	2,428 5714	2,78571 429	2,571 4286	1,21 4286	33,3 348

Для модели llama3.2:3b

	Точно сть	Релевантно сть	Полно та	Галлюцина ции	Время ответа , мс
Кто ректор?	3	3	3	1	36346
Что такое академический отпуск и почему его можно взять?	2	3	2	1	24849
Какие документы нужно нести в военкомат для отсрочки?	3	3	3	1	27572
Как пересдать экзамен, пропущенный по уважительной причине?	2	2	2	2	34997
Какие уважительные причины бывают?	3	3	2	1	32219
Что такое пересдача при неудовлетворительной оценке за экзамен	2	2	2	3	44382

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

и как она происходит?					
Что делать если не сдал экзамен?	1	1	1	1	45924
Что такое летняя практика?	1	1	1	1	28707
Что такое электронный студенческий билет?	3	3	2	1	30611
Где электронный студенческий билет доступен?	3	3	3	1	29145
Что такое КУД?	1	1	1	3	29835
Где найти расписание?	1	2	1	3	27108
Что такое независимый экзамен и какие они бывают?	1	1	3	2	36413
Какие документы нужны первокурснику для поступления?	2	2	2	2	32206
Среднее значение	2	2,142857	2	1,642857	32,87957

Для модели tinyllama

	Точнос ть	Релевантно сть	Полно та	Галлюцина ции	Время ответа
Кто ректор?	1	1	1	3	9153
Что такое академический отпуск и почему его можно взять?	1	2	1	2	24464
Какие документы нужно нести в военкомат для отсрочки?	1	1	1	2	32179
Как пересдать экзамен, пропущенный по уважительной причине?	1	1	1	3	28644
Какие уважительные причины бывают?	1	1	1	2	28382
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	1	1	1	2	14351
Что делать если не сдал экзамен?	1	1	1	1	16517
Что такое летняя практика?	1	1	1	3	13585
Что такое электронный студенческий билет?	1	1	1	2	25730
Где электронный студенческий билет доступен?	1	1	1	3	22827
Что такое КУД?	2	2	2	2	26711
Где найти расписание?	1	1	1	2	16190
Что такое независимый экзамен и какие они бывают?	1	1	1	3	8796
Какие документы нужны первокурснику для поступления?	1	1	1	3	30605
Среднее значение	1,071429	1,142857	1,071429	2,357143	21,29529

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Для модели mistral:7b

	Точно сть	Релевантно сть	Полно та	Галлюцина ции	Врем я ответ а
Кто ректор?	3	3	2	1	44139
Что такое академический отпуск и почему его можно взять?	3	3	3	1	76014
Какие документы нужно нести в военкомат для отсрочки?	2	2	1	1	69289
Как пересдать экзамен, пропущенный по уважительной причине?	2	3	2	1	84977
Какие уважительные причины бывают?	2	2	2	1	89789
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	2	2	2	1	105829
Что делать если не сдал экзамен?	2	3	2	1	100853
Что такое летняя практика?	3	3	2	1	96611
Что такое электронный студенческий билет?	2	2	2	2	95761
Где электронный студенческий билет доступен?	3	3	2	1	80627
Что такое КУД?	1	1	1	1	90959
Где найти расписание?	1	1	1	1	82550
Что такое независимый экзамен и какие они бывают?	2	2	3	1	108387
Какие документы нужны первокурснику для поступления?	2	2	2	2	80833
Среднее значение	2,142857	2,285714	1,928571	1,142857	86,187

Для модели qwen2.5:7b

	Точн ость	Релеван тность	Пол нота	1	Время ответа
Кто ректор?	3	3	3	1	57975
Что такое академический отпуск и почему его можно	3	3	3	1	68488
Изм.	Лист	№ докум.	Подп.	Дата	
RU.17701729.05.09 81 04-1					
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата	

взять?					
Какие документы нужно нести в военкомат для отсрочки?	1	2	1	1	55651
Как пересдать экзамен, пропущенный по уважительной причине?	1	2	1	2	85462
Какие уважительные причины бывают?	1	2	1	1	76156
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	2	3	2	2	87050
Что делать если не сдал экзамен?	3	3	3	1	85256
Что такое летняя практика?	2	2	2	1	82821
Что такое электронный студенческий билет?	2	2	2	3	78270
Где электронный студенческий билет доступен?	1	1	1	1	72940
Что такое КУД?	3	3	3	1	79206
Где найти расписание?	1	1	1	3	69747
Что такое независимый экзамен и какие они бывают?	1	1	1	3	55769
Какие документы нужны первокурснику для поступления?	1	1	1	3	56718
Среднее значение	1,785 714	2,07142 9	1,785 714	1,714 286	72,2506 4

Для модели gemma2:2b

	Точность	Релевантность	Полнота	Галлюцинации	Время ответа
Кто ректор?	3	3	3	1	13421
Что такое академический отпуск и почему его можно взять?	2	2	2	1	17690
Какие документы нужно нести в военкомат для отсрочки?	1	2	1	1	15976
Как пересдать экзамен, пропущенный по уважительной причине?	1	1	1	1	10923
Какие уважительные причины бывают?	1	1	1	1	12767
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	2	3	2	1	20284
Что делать если не сдал экзамен?	2	3	2	1	22755
Что такое летняя практика?	1	1	1	1	13272
Что такое электронный студенческий билет?	1	1	1	1	15400
Где электронный студенческий билет доступен?	1	1	2	1	17506
Что такое КУД?	1	1	1	1	15107
Где найти расписание?	1	1	1	1	13439
Что такое независимый экзамен и какие они бывают?	1	1	1	1	12662
Какие документы нужны первокурснику	1	1	1	1	12997

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

для поступления?					
Среднее значение	1,3571 43	1,571429	1,4285 71	1	15,299 93

Для модели phi3:3.8b

	Точность	Релевантность	Полнота	Галлюцинации	Время ответа
Кто ректор?	1	1	1	3	36169
Что такое академический отпуск и почему его можно взять?	3	3	3	3	201128
Какие документы нужно нести в военкомат для отсрочки?	2	2	1	3	399536
Как пересдать экзамен, пропущенный по уважительной причине?	1	2	1	2	28442
Какие уважительные причины бывают?	2	2	2	2	29854
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	1	2	2	2	52407
Что делать если не сдал экзамен?	2	2	1	2	40253
Что такое летняя практика?	2	2	1	3	37526
Что такое электронный студенческий билет?	1	2	1	3	312154
Где электронный студенческий билет доступен?	1	2	1	2	35421
Что такое КУД?	2	2	2	2	54389
Где найти расписание?	1	1	1	2	43568
Что такое независимый экзамен и какие они бывают?	1	2	2	3	65436
Какие документы нужны первокурснику для поступления?	1	2	1	3	87432
Среднее значение	1,5	1,92857 1	1,42 8571	2,5	101,693 9

Для модели llama3.1:8b

	Точность	Релевантность	Полнота	Галлюцинации	Время ответа
Кто ректор?	3	3	3	1	72588
Что такое академический отпуск и почему его можно взять?	2	3	2	1	52458
Какие документы нужно нести в военкомат для отсрочки?	2	2	2	2	57450
Как пересдать экзамен, пропущенный по уважительной причине?	3	3	2	1	81483

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

Какие уважительные причины бывают?	2	3	1	1	61045
Что такое пересдача при неудовлетворительной оценке за экзамен и как она происходит?	2	2	3	2	107042
Что делать если не сдал экзамен?	2	2	2	1	82246
Что такое летняя практика?	2	3	2	1	70190
Что такое электронный студенческий билет?	3	3	2	1	67133
Где электронный студенческий билет доступен?	2	3	1	1	62065
Что такое КУД?	1	2	1	1	68240
Где найти расписание?	1	2	1	1	66094
Что такое независимый экзамен и какие они бывают?	1	2	1	1	54102
Какие документы нужны первокурснику для поступления?	1	1	1	1	55615
Среднее значение	1,928571	2,428571	1,714286	1,142857	68,41079

Сравнение моделей LMM по результатам эксперимента

Для упрощения сравнения моделей, введем величину Q (Quality), являющуюся средним арифметическим средних оценок точности, релевантности, полноты и (4 - галлюцинации) модели.

	Точность	Релевантность	Полнота	Галлюцинации	Время ответа, с	Q
qwen2.5:3b	2,428571	2,785714	2,571429	2,785714	33,33477	2,642857
llama3.2:3b	2	2,142857	2	2,357143	32,87957	2,125
tinylama	1,071429	1,142857	1,071429	1,642857	21,29529	1,232143
mistral:7b	2,142857	2,285714	1,928571	2,857143	86,187	2,303571
qwen2.5:7b	1,785714	2,071429	1,785714	2,285714	72,25064	1,982143
gemma2:2b	1,357143	1,571429	1,428571	3	15,29993	1,839286
phi3:3.8b	1,5	1,928571	1,428571	1,5	101,6939	1,589286
llama3.1:8b	1,928571	2,428571	1,714286	2,857143	68,41079	2,232143

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата




Рисунок 8, диаграмма метрик



Рисунок 9, диаграмма времени ответа

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата




Рисунок 10, общая диаграмма

По итогам эксперимента выбрана модель qwen2.5:3b.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

5. ИСТОЧНИКИ, ИСПОЛЬЗОВАННЫЕ ПРИ РАЗРАБОТКЕ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.401-78: Текст программы. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
10. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
11. ГОСТ 19.505-79: Руководство оператора. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
12. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
13. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ 1

ПЕРЕЧЕНЬ ТЕРМИНОВ

Селф-хост - размещение веб-сервисов на собственных серверах, а не на сторонних хостингах.

Деплой – процесс развертывания и запуска готового программного обеспечения на сервере или в облачной инфраструктуре, чтобы пользователи могли им пользоваться.

Даунтайм - это время простоя, когда веб-сайт или система не функционируют, что мешает пользователям получить доступ к сервисам.

Фреймворк - программная платформа, определяющая структуру программной системы; программное обеспечение, облегчающее разработку и объединение разных компонентов большого программного проекта.

Пайплайн - это последовательность этапов или шагов, через которые проходит задача, проект или процесс от начала до завершения.

Раннер (в GitLab) – это инструмент, который используется для автоматизации процессов непрерывной интеграции (CI) и непрерывного развертывания (CD). Он запускает задачи (jobs), такие как сборка, тестирование и развертывание приложений, и отправляет результаты обратно в GitLab.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 81 04-1				
Инв. № подл.	Подп. и дата	Взам. инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]