

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Программная инженерия»

СОГЛАСОВАНО

Магистр наук о данных, старший
разработчик в X5 Tech

_____ В. Е. Козловский

«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия",
старший преподаватель департамента
программной инженерии

_____ Н. А. Павлов

«__» _____ 2026 г.

**РАЗРАБОТКА ИНТЕЛЛЕКТУАЛЬНОГО АССИСТЕНТА ДЛЯ
ОБРАЗОВАТЕЛЬНЫХ УЧРЕЖДЕНИЙ.**

Руководство оператора

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.05.09-34 РО 01-1-ЛУ

Исполнители:

Студент группы БПИ244

_____ / Л. Д. Субботин /

«__» _____ 2026 г.

Студент группы БПИ235

_____ / А. К. Соколова /

«__» _____ 2026 г.

Студент группы БПИ236

_____ / С. Е. Растворов /

«__» _____ 2026 г.

2026

Инд.№ подп	Подп. и дата	Взам. инв.№	Инд.№ дубл.	Подп. и дата

УТВЕРЖДЕН

RU.17701729.05.09-34 ПО 01-1-ЛЮ

**РАЗРАБОТКА ИНТЕЛЛЕКТУАЛЬНОГО АССИСТЕНТА ДЛЯ
ОБРАЗОВАТЕЛЬНЫХ УЧРЕЖДЕНИЙ.**

Руководство оператора

RU.17701729.05.09-34 ПО 01-1

Листов 20

Инв.№ подл	Подп. и дата	Взам. инв.№	Инв.№ дубл.	Подп. и дата

АННОТАЦИЯ

Руководство оператора — программный документ, содержащий сведения, необходимые оператору для обеспечения корректного функционирования программного комплекса, включая порядок запуска, сценарии взаимодействия с интерфейсами и рекомендации по устранению типовых неисправностей.

Настоящее Руководство оператора на разработку «Разработка интеллектуального ассистента для образовательных учреждений» содержит следующие разделы: «Назначение программы», «Условия выполнения программы», «Выполнение программы», «Сообщения оператору», «Перечень терминов», «Источники, использованные при разработке» [13].

В разделе «Назначение программы» приведены функциональное и эксплуатационное назначение программного комплекса, а также перечень реализованных функций.

В разделе «Условия выполнения программы» описаны требования к аппаратным и программным средствам серверной и клиентской частей системы, климатические условия эксплуатации и требования к квалификации персонала.

Раздел «Выполнение программы» содержит пошаговые инструкции по развёртыванию системы, запуску сервисов и работе с каждым из клиентских интерфейсов — Telegram-ботом, веб-клиентом и REST API.

В разделе «Сообщения оператору» перечислены диагностические сообщения и коды ошибок, возникающие в ходе эксплуатации, с указанием возможных причин и рекомендуемых корректирующих действий.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.
6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.
7. ГОСТ 19.505-79 [13]: Руководство оператора. Требования к содержанию и оформлению.

Изменения к данному Руководству оператора оформляются согласно ГОСТ 19.603-78 [11], ГОСТ 19.604-78 [12].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. НАЗНАЧЕНИЕ ПРОГРАММЫ	4
1.1. Функциональное назначение	4
1.2. Эксплуатационное назначение	4
2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ	6
2.1. Условия эксплуатации	6
2.1.1. Климатические условия эксплуатации	6
2.1.2. Требования к видам обслуживания	6
2.1.3. Требования к численности и квалификации персонала	6
2.2. Требования к составу и параметрам технических средств	7
2.2.1. Требования к серверному оборудованию	7
2.2.2. Требования к программным средствам	7
2.2.3. Требования к клиентскому оборудованию	8
3. ВЫПОЛНЕНИЕ ПРОГРАММЫ	9
3.1. Загрузка и первичное развёртывание системы	9
3.2. Запуск программы	10
3.3. Работа через Telegram-бот	10
3.4. Работа через веб-интерфейс	11
3.5. Взаимодействие через REST API	11
4. СООБЩЕНИЯ ОПЕРАТОРУ	13
4.1. HTTP 401 Unauthorized	13
4.2. HTTP 429 Too Many Requests	13
4.3. Ошибка обработки медиафайла (MediaProcessingError)	13
4.4. Превышение времени ожидания ответа от языковой модели (LLM Timeout)	14
4.5. Отсутствие релевантных фрагментов («Ответ не найден»)	14
4.6. Ошибка подключения к базе данных	14
ПЕРЕЧЕНЬ ТЕРМИНОВ	16
ИСТОЧНИКИ, ИСПОЛЬЗОВАННЫЕ ПРИ РАЗРАБОТКЕ	18

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 РО 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1. Функциональное назначение

Программный комплекс «Разработка интеллектуального ассистента для образовательных учреждений» предназначен для автоматизированной информационно-справочной поддержки участников образовательного процесса — студентов, преподавателей и административного персонала высших учебных заведений. В основе системы лежит технология дополненной генерации с извлечением (Retrieval-Augmented Generation, RAG), которая обеспечивает точные и верифицируемые ответы за счёт семантического поиска по корпусу загруженных учебных документов с последующей генерацией ответа языковой моделью.

Перечень реализованных функций:

- приём запросов пользователей в трёх форматах — текстовом, графическом (JPEG/PNG) и документальном (PDF) — через унифицированный REST API;
- оптическое распознавание символов изображений с помощью движка Tesseract (языки: rus+eng) с предварительным показом распознанного текста пользователю;
- извлечение текстового содержимого PDF-документов постранично без необходимости установки дополнительных системных зависимостей;
- семантическое векторное представление текстовых фрагментов с помощью модели cointegrated/rubert-tiny2 и индексация в векторном хранилище ChromaDB;
- поиск Top-4 наиболее релевантных фрагментов документов по косинусному сходству и передача их в качестве контекста языковой модели mistral:latest;
- формирование ответа с обязательным указанием источников (наименование документа, номер страницы), а также служебных метаданных: время обработки, оценка уверенности, признак резервного режима;
- ведение персистентного журнала всех обращений в реляционной базе данных PostgreSQL с хранением идентификатора пользователя, типа контента и текстов запроса и ответа;
- экспорт метрик производительности (счётчики запросов, гистограммы времени ответа, гейджи ошибок) через эндпоинт /metrics в формате Prometheus.

1.2. Эксплуатационное назначение

Программный комплекс рассчитан на развёртывание в изолированной сетевой инфраструктуре образовательного учреждения без зависимости от сторонних облачных провайдеров. Все

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

компоненты упакованы в Docker-контейнеры, что обеспечивает воспроизводимое окружение и независимость от конфигурации хост-системы.

Целевой сценарий эксплуатации — обслуживание фокус-группы численностью 50–100 активных пользователей при пиковой нагрузке до 300 запросов в сутки. Система функционирует в круглосуточном режиме без участия оператора в промежутках между плановым обслуживанием.

Комплекс ориентирован на следующие практические сценарии применения:

- поиск ответа на вопрос по содержанию учебной дисциплины, методического пособия или нормативного регламента учреждения;
- уточнение требований учебного плана, условий промежуточной аттестации или порядка оформления курсовых работ;
- распознавание и последующий анализ сфотографированного фрагмента учебника или отсканированного документа;
- интеграция со сторонними информационными системами университета посредством REST API.

Система предоставляет три независимых клиентских интерфейса, ориентированных на различные категории пользователей:

- Telegram-бот — основной канал для конечных пользователей, доступный на любом устройстве с установленным приложением Telegram;
- веб-интерфейс (порт 8501) — браузерный Streamlit-клиент с историей диалога и отображением источников;
- REST API (порт 8000) — программный интерфейс для интеграции со сторонними системами, защищённый заголовком X-API-Key.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

2.1. Условия эксплуатации

2.1.1. Климатические условия эксплуатации

Программный комплекс функционирует на базе серверного оборудования, размещаемого в помещениях с поддерживаемыми климатическими параметрами. Специальных требований сверх стандартных норм для серверных помещений не предъявляется: температура окружающего воздуха от +18 °С до +25 °С, относительная влажность не более 80% без конденсации, нормальное атмосферное давление.

2.1.2. Требования к видам обслуживания

Для обеспечения стабильной долгосрочной работы системы необходимо осуществлять следующие виды периодического обслуживания:

- **Обновление корпуса знаний.** При добавлении или замене учебных документов оператор помещает файлы формата PDF или DOCX в каталог `data_and_documents` и запускает скрипт переиндексации (`index_documents`). Старые векторные индексы перезаписываются автоматически. Рекомендуемая периодичность — по мере обновления учебных материалов.
- **Резервное копирование.** Резервной копии подлежат: директория базы данных PostgreSQL (содержащая журнал обращений) и директория векторного хранилища ChromaDB (содержащая индексы эмбедингов). Рекомендуемая периодичность — не реже одного раза в неделю.
- **Мониторинг и масштабирование.** Метрики производительности (латентность, процент ошибок, количество запросов) доступны через эндпоинт `/metrics` и могут визуализироваться в Grafana или аналогичной системе. При систематическом превышении целевого времени отклика следует рассмотреть увеличение ресурсов сервера или подключение GPU-ускорителя.

2.1.3. Требования к численности и квалификации персонала

Для эксплуатации комплекса задействованы две категории персонала:

Конечный пользователь — студент или преподаватель. Для работы с Telegram-ботом достаточно базовых навыков работы со смартфоном или персональным компьютером и приложением Telegram. Для доступа к веб-интерфейсу необходим современный браузер с поддержкой HTML5. Специальной технической подготовки не требуется.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 РО 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Системный администратор (оператор) — специалист, ответственный за развёртывание и обслуживание системы. Обязательный уровень компетентности:

- уверенное владение командной строкой операционной системы Linux;
- практический опыт работы с Docker Engine и Docker Compose (создание и управление многоконтейнерными приложениями);
- базовое понимание принципов работы REST API и HTTP-заголовков авторизации;
- навыки администрирования PostgreSQL на уровне создания резервных копий и просмотра содержимого таблиц.

2.2. Требования к составу и параметрам технических средств

2.2.1. Требования к серверному оборудованию

Минимальные требования (достаточны для CPU-режима, время ответа 30–60 с):

- центральный процессор: 4-ядерный CPU с тактовой частотой не менее 2,0 ГГц;
- оперативная память: не менее 8 ГБ;
- дисковое пространство: не менее 15 ГБ свободного пространства (рекомендуется SSD) — из них: языковая модель Mistral 4 ГБ, эмбединговая модель 0,5 ГБ, базы данных и документы — остальное;
- сетевой интерфейс: пропускная способность не менее 10 МБит/с.

Рекомендуемые требования (обеспечивают время ответа ≤ 5 с при использовании GPU):

- центральный процессор: 8-ядерный CPU с тактовой частотой не менее 3,0 ГГц;
- графический ускоритель: GPU NVIDIA с поддержкой CUDA и объёмом видеопамяти не менее 8 ГБ (VRAM);
- оперативная память: не менее 16 ГБ;
- дисковое пространство: не менее 30 ГБ (SSD);
- сетевой интерфейс: пропускная способность не менее 100 МБит/с.

2.2.2. Требования к программным средствам

На серверном хосте должно быть установлено следующее программное обеспечение:

- операционная система семейства Linux (рекомендуется Ubuntu 22.04 LTS или Debian 12 Bookworm);
- Docker Engine версии 24.0 или выше с плагином Docker Compose версии 2.20 или выше;
- Python 3.12 или выше — только при необходимости локальной отладки вне контейнеров;
- драйвер CUDA (при наличии GPU NVIDIA) совместимой версии, поддерживаемой Ollama.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Все зависимости приложения (Python-библиотеки, языковые модели, системные пакеты) устанавливаются автоматически при первом запуске Docker Compose и не требуют ручного конфигурирования.

2.2.3. Требования к клиентскому оборудованию

Для работы с Telegram-ботом: смартфон или персональный компьютер с установленным приложением Telegram актуальной версии и доступом к сети Интернет.

Для работы с веб-интерфейсом: любое устройство (ПК, планшет, смартфон) с браузером, поддерживающим HTML5 и JavaScript (Google Chrome, Mozilla Firefox, Microsoft Edge, Apple Safari актуальных версий), и сетевым доступом к хосту с развёрнутым комплексом.

Для прямого обращения к REST API: клиент, поддерживающий отправку HTTP-запросов с произвольными заголовками (Postman, curl, PowerShell Invoke-RestMethod, любая HTTP-клиентская библиотека).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. ВЫПОЛНЕНИЕ ПРОГРАММЫ

3.1. Загрузка и первичное развёртывание системы

Первичное развёртывание выполняется системным администратором однократно. Последующие запуски не требуют повторного прохождения всех шагов.

1. Открыть терминал на сервере и клонировать репозиторий проекта из системы контроля версий:

```
git clone https://github.com/lvfky/Intelligent-Assistant-for-Educational-Institutions.git
cd Intelligent-Assistant-for-Educational-Institutions
```

2. На основе шаблона создать конфигурационный файл окружения:

```
cp .env.example .env
```

Открыть файл `.env` в текстовом редакторе и задать обязательные переменные:

- `BOT_TOKEN` — уникальный токен Telegram-бота, полученный у `@BotFather`;
- `DATABASE_URL` — строка подключения к СУБД PostgreSQL вида `postgresql+asyncpg://user:password@db:5432/dbname`;
- `API_KEY` — произвольный секретный ключ для защиты эндпоинта `/ask`;
- `OLLAMA_BASE_URL` — адрес сервиса Ollama (по умолчанию `http://ollama:11434`).

3. Разместить учебные документы (файлы PDF, DOCX) в каталоге `data_and_documents`. Каталог может содержать вложенные поддиректории; рекурсивная индексация поддерживается.

4. Запустить сборку и первичный старт всех сервисов:

```
docker compose --profile dev up --build
```

Дождаться появления в консоли сообщений о готовности каждого из сервисов: `db` (PostgreSQL), `server` (FastAPI), `client` (Streamlit), `bot` (aiogram).

5. После успешного старта выполнить индексацию документов в векторное хранилище. Индексация запускается однократно и при необходимости повторяется после обновления корпуса документов. Команда для запуска:

```
docker compose exec server python index_documents.py
```

По завершении в журнале контейнера `server` появится сообщение о количестве проиндексированных фрагментов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 РО 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Примечание. При последующих запусках системы без изменения конфигурации достаточно выполнить команду `docker compose --profile dev up -d`. Повторная сборка образов и переиндексация не требуются.

3.2. Запуск программы

После первичного развёртывания повторный запуск системы сводится к одной команде:

```
docker compose --profile dev up -d
```

Для проверки состояния контейнеров используется:

```
docker compose ps
```

Все четыре сервиса (db, server, client, bot) должны находиться в состоянии running. При необходимости просмотреть журнал конкретного сервиса:

```
docker compose logs -f server
```

Для остановки системы:

```
docker compose --profile dev down
```

3.3. Работа через Telegram-бот

Telegram-бот является основным клиентским интерфейсом, ориентированным на конечных пользователей.

Начало работы. Найти бота по его имени пользователя (username) в приложении Telegram и нажать кнопку «Запустить» или отправить команду `/start`. Бот отобразит приветственное сообщение и зарегистрирует пользователя в базе данных, сохранив его Telegram ID и временную метку первого обращения.

Текстовый запрос. Ввести вопрос на русском языке в свободной форме и отправить его боту. Система проведёт семантический поиск по проиндексированному корпусу документов и сформирует ответ с указанием источников. Примеры корректных запросов: «Каковы требования к курсовой работе по программной инженерии?», «Где найти расписание промежуточной аттестации?».

Запрос с изображением. Прикрепить к сообщению фотографию или отсканированное изображение страницы учебника, рукописного текста или экрана с информацией. Бот распознает текст с помощью Tesseract OCR, отобразит предпросмотр распознанного содержимого и запросит подтверждение перед отправкой в RAG-конвейер. Поддерживаемые форматы: JPEG, PNG. Максимальный размер файла: 20 МБ.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 РО 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Запрос с PDF-файлом. Прикрепить PDF-документ как вложение (не как изображение). Бот извлечёт текстовый слой постранично, отобразит предпросмотр первых 500 символов и запросит подтверждение. Документы, содержащие только растровые страницы без текстового слоя, не поддерживаются.

Формат ответа. После обработки запроса бот отправляет ответ, содержащий:

- сгенерированный текст ответа (или релевантные фрагменты в резервном режиме);
- список источников с наименованием документа и номерами страниц;
- служебную информацию: оценку уверенности и общее время обработки.

После получения ответа диалог остаётся в активном состоянии — следующий вопрос можно задать без повторной отправки команды /start.

3.4. Работа через веб-интерфейс

Веб-интерфейс реализован на базе Streamlit и предоставляет чат-подобный интерфейс с историей диалога, доступный в браузере.

Открытие интерфейса. Перейти в браузере по адресу <https://assistant-about-hse.ru>. При локальном развёртывании — <http://localhost:8501>.

Отправка запроса. В поле ввода в нижней части страницы ввести вопрос и нажать кнопку «Отправить» или клавишу Enter. Ответ системы, включая ссылки на источники, отобразится в области истории диалога. История сохраняется в рамках текущей сессии браузера.

Просмотр источников. Если в конфигурации сервера задан параметр SHOW_SOURCES, под ответом отображается раскрываемый список источников с путями к файлам и номерами страниц.

Завершение работы. Закрытие вкладки браузера завершает сессию без влияния на работу серверной части. Все запросы зафиксированы в журнале PostgreSQL независимо от того, была ли закрыта вкладка браузера.

3.5. Взаимодействие через REST API

REST API предоставляет программный доступ к RAG-конвейеру для интеграции со сторонними информационными системами.

Базовый URL: <https://assistant-about-hse.ru>

Авторизация. Все запросы к эндпоинту /ask должны содержать HTTP-заголовок X-API-Key со значением, совпадающим с переменной API_KEY из файла .env. Если переменная API_KEY не задана, эндпоинт доступен без авторизации (только в режиме разработки).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Ограничение частоты запросов. Действует лимит не более 10 запросов в минуту с одного IP-адреса. При превышении сервер возвращает HTTP 429 Too Many Requests.

Отправка запроса (метод POST /ask):

```
POST /ask HTTP/1.1
Host: assistant-about-hse.ru
Content-Type: application/json
X-API-Key: <секретный_ключ>
```

```
{"question": "Каков порядок оформления академической задолженности?"}
```

Пример вызова средствами PowerShell:

```
Invoke-RestMethod `
  -Method POST `
  -Uri https://assistant-about-hse.ru/ask `
  -ContentType "application/json" `
  -Headers @{"X-API-Key" = "<секретный_ключ>"} `
  -Body '{"question": "Каков порядок оформления академической задолженности?"}'
```

Структура ответа:

```
{
  "answer": "Для оформления академической задолженности необходимо...",
  "sources": [
    {"title": "Положение об аттестации", "source": "/docs/положение.pdf", "page": 12}
  ],
  "metadata": {
    "model": "mistral:latest",
    "confidence": 0.87,
    "total_time_ms": 4320,
    "fallback": false
  }
}
```

Просмотр документации API. Интерактивная документация OpenAPI доступна по адресу <https://assistant-about-hse.ru/docs> без авторизации.

Проверка работоспособности. Эндпоинт GET /health возвращает статус сервера без авторизации и может использоваться системой мониторинга для проверки доступности сервиса.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. СООБЩЕНИЯ ОПЕРАТОРУ

В процессе эксплуатации программного комплекса оператор или конечный пользователь может столкнуться со следующими диагностическими сообщениями. Для каждого случая приведены вероятная причина и рекомендуемые действия.

4.1. HTTP 401 Unauthorized

Условие возникновения. Сообщение возвращается при обращении к защищённым маршрутам API (/ask, /metrics) без заголовка X-API-Key или при несоответствии переданного значения ключа секрета, заданному в переменной окружения API_KEY.

Рекомендуемые действия оператора:

- проверить файл .env на сервере: убедиться, что переменная API_KEY задана корректно и не содержит лишних пробелов или переносов строки;
- перезапустить серверный контейнер командой `docker compose restart server` для применения изменений;
- убедиться, что клиент передаёт ключ именно в заголовке X-API-Key, а не в теле запроса или параметрах URL.

4.2. HTTP 429 Too Many Requests

Условие возникновения. Сообщение возвращается, когда количество запросов с одного IP-адреса превышает установленный лимит — 10 запросов в течение одной минуты.

Рекомендуемые действия оператора:

- при легитимной нагрузке, превышающей лимит, увеличить значение параметра RATE_LIMIT_PER_MINUTE в конфигурации сервера и перезапустить контейнер;
- при признаках автоматизированного злоупотребления — добавить IP-адрес источника в список блокировок на уровне сетевого экрана.

4.3. Ошибка обработки медиафайла (MediaProcessingError)

Условие возникновения. Сообщение отображается пользователю в Telegram-боте, если системе не удалось загрузить, декодировать или распознать прикрепленный файл. Возможные причины: повреждение файла, неподдерживаемый формат, превышение допустимого размера (20 МБ), или истечение времени ожидания при загрузке через Telegram Bot API.

Рекомендуемые действия оператора:

- попросить пользователя убедиться, что файл не повреждён, и повторить отправку;

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- при системном характере ошибки — проверить журналы контейнера бота: `docker compose logs bot | grep ERROR`;
- при ошибках OCR-распознавания убедиться, что пакет языка Tesseract rus установлен корректно: `docker compose exec bot tesseract --list-langs`.

4.4. Превышение времени ожидания ответа от языковой модели (LLM Timeout)

Условие возникновения. Языковая модель `mistral:latest` не завершила генерацию ответа в течение отведённого времени (таймаут генерации — 18 с, общий таймаут запроса — 20 с). В этом случае система автоматически переключается в резервный режим: пользователю возвращаются найденные фрагменты документов без сгенерированного текста. Признак резервного режима (`"fallback": true`) фиксируется в поле `metadata` ответа.

Рекомендуемые действия оператора:

- проверить доступность сервиса Ollama: `docker compose ps ollama` — контейнер должен находиться в состоянии `running`;
- оценить загрузку CPU/GPU сервера; при систематических таймаутах рассмотреть подключение GPU-ускорителя;
- при необходимости увеличить значение таймаута в конфигурации (`config.py`) и перезапустить серверный контейнер.

4.5. Отсутствие релевантных фрагментов («Ответ не найден»)

Условие возникновения. Семантический поиск в векторном хранилище ChromaDB не выявил ни одного фрагмента с косинусным сходством, достаточным для формирования ответа. Система возвращает сообщение о невозможности ответить на основе имеющихся документов.

Данное поведение является штатным механизмом защиты от фактических ошибок: система не генерирует ответ при отсутствии подтверждающего контекста в загруженных документах.

Рекомендуемые действия оператора:

- расширить корпус знаний: добавить в каталог `data_and_documents` документы, охватывающие тематику запроса, и запустить переиндексацию;
- если документы уже загружены — проверить, что индексация была успешно завершена: `docker compose logs server | grep "indexed"`;
- при необходимости скорректировать порог косинусного сходства (`SIMILARITY_THRESHOLD`) в конфигурации сервера.

4.6. Ошибка подключения к базе данных

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

RU.17701729.05.09-34 PO 01-1

Условие возникновения. Серверный контейнер не может установить соединение с PostgreSQL. Журнал контейнера server содержит строки вида `asyncpg.exceptions.ConnectionRefusedError` или `could not connect to server`.

Рекомендуемые действия оператора:

- убедиться, что контейнер базы данных запущен: `docker compose ps db`;
- проверить корректность строки подключения `DATABASE_URL` в файле `.env`;
- при первом запуске дождаться полной инициализации PostgreSQL (обычно 5–10 секунд после старта контейнера db).

Сообщение / код	Возможная причина	Действие оператора
HTTP 401 Unauthorized	Отсутствует или неверен заголовок X-API-Key	Проверить <code>.env</code> , перезапустить контейнер server
HTTP 429 Too Many Requests	Превышен лимит 10 запросов/мин с одного IP	Скорректировать <code>RATE_LIMIT_PER_MINUTE</code> или добавить IP в блокировку
MediaProcessingError	Файл повреждён, неверный формат или превышен размер 20 МБ	Просмотреть логи bot, проверить установку Tesseract rus
LLM Timeout / "fallback": true	Модель не завершила генерацию за 18 с	Проверить контейнер Ollama, нагрузку CPU/GPU, увеличить таймаут
«Ответ не найден»	В корпусе нет документов по тематике запроса	Добавить документы, запустить <code>index_documents</code>
ConnectionRefusedError	Контейнер db не запущен или неверна <code>DATABASE_URL</code>	Проверить статус db, исправить <code>.env</code>

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПЕРЕЧЕНЬ ТЕРМИНОВ

1. **API** (от англ. Application Programming Interface) — программный интерфейс взаимодействия компонентов программной системы; в данном комплексе — HTTP REST API сервера FastAPI, принимающий запросы и возвращающий ответы в формате JSON.
2. **ChromaDB** — векторная база данных с открытым исходным кодом и производительным Rust-бэкендом; обеспечивает персистентное хранение эмбеддингов и поиск ближайших соседей по косинусному сходству.
3. **Docker Compose** — инструмент оркестрации многоконтейнерных приложений на основе конфигурационного файла YAML; обеспечивает управление жизненным циклом всех сервисов комплекса единой командой.
4. **Embedding (эмбеддинг)** — числовой вектор фиксированной размерности, кодирующий семантическое содержание текстового фрагмента. Близкие по смыслу тексты имеют векторные представления с высоким косинусным сходством.
5. **Fallback-режим** — резервный режим ответа системы: активируется при истечении таймаута языковой модели; сервер возвращает найденные фрагменты документов без генерации связного текста ответа.
6. **FastAPI** — высокопроизводительный Python-фреймворк для создания REST API на основе стандарта ASGI; поддерживает асинхронную обработку запросов и автоматическую генерацию документации OpenAPI.
7. **FSM** (от англ. Finite State Machine) — конечный автомат; в Telegram-боте определяет текущее состояние диалога с пользователем (например, `waiting_for_content`).
8. **JSON** (от англ. JavaScript Object Notation) — текстовый формат сериализации данных; используется для передачи запросов и ответов через REST API комплекса.
9. **LLM** (от англ. Large Language Model) — большая языковая модель; нейронная сеть, обученная на масштабных текстовых корпусах и генерирующая связный текст по входному запросу. В комплексе используется модель `mistral:latest`.
10. **OCR** (от англ. Optical Character Recognition) — оптическое распознавание символов; преобразование изображения с текстом в машиночитаемую строку. Реализовано через движок Tesseract с поддержкой языков `rus+eng`.
11. **Ollama** — программный инструмент для локального запуска языковых моделей на CPU или GPU без зависимости от облачных API-провайдеров.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 РО 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

12. **PostgreSQL** — объектно-реляционная СУБД с открытым исходным кодом; используется для хранения журнала обращений пользователей с ACID-гарантиями.
13. **Prometheus** — система мониторинга и сбора метрик с открытым исходным кодом; в комплексе метрики производительности экспортируются через эндпоинт `/metrics`.
14. **RAG** (от англ. Retrieval-Augmented Generation) — метод дополненной генерации с извлечением: перед формированием ответа из базы знаний извлекаются семантически релевантные фрагменты, которые передаются языковой модели в качестве контекста.
15. **REST** (от англ. Representational State Transfer) — архитектурный стиль построения распределённых приложений на основе HTTP-запросов без сохранения состояния на сервере между вызовами.
16. **Streamlit** — Python-фреймворк для быстрого создания интерактивных веб-приложений; используется для реализации браузерного чат-интерфейса комплекса.
17. **Telegram-бот** — программный агент, взаимодействующий с пользователями мессенджера Telegram через Telegram Bot API; в комплексе реализован на фреймворке `aiogram 3.x`.
18. **Токен** — минимальная единица текста при обработке языковой моделью; приблизительно соответствует слову или части слова. Используется для ограничения длины фрагментов при индексации документов (500 токенов с перекрытием 100 токенов).
19. **X-API-Key** — HTTP-заголовок авторизации, обязательный при обращении к защищённым эндпоинтам сервера; значение должно совпадать с переменной `API_KEY` из файла конфигурации `.env`.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ИСТОЧНИКИ, ИСПОЛЬЗОВАННЫЕ ПРИ РАЗРАБОТКЕ

1. ГОСТ 19.101-77 Виды программ и программных документов // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
2. ГОСТ 19.102-77 Стадии разработки // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
3. ГОСТ 19.103-77 Обозначения программ и программных документов // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
4. ГОСТ 19.104-78 Основные надписи // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
5. ГОСТ 19.105-78 Общие требования к программным документам // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
6. ГОСТ 19.106-78 Требования к программным документам, выполненным печатным способом // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
7. ГОСТ 19.201-78 Техническое задание. Требования к содержанию и оформлению // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
8. ГОСТ 19.301-79 Программа и методика испытаний. Требования к содержанию и оформлению // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
9. ГОСТ 19.401-78 Текст программы. Требования к содержанию и оформлению // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
10. ГОСТ 19.404-79 Пояснительная записка. Требования к содержанию и оформлению // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
11. ГОСТ 19.603-78 Общие правила внесения изменений // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

12. ГОСТ 19.604-78 Правила внесения изменений в программные документы, выполненные печатным способом // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
13. ГОСТ 19.505-79 Руководство оператора. Требования к содержанию и оформлению // Официальное издание. Единая система программной документации: Сборник национальных стандартов. — М.: Стандартинформ, 2010.
14. Lewis P., Perez E., Piktus A. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. — 2020. — Vol. 33. — P. 9459–9474.
15. Документация FastAPI. — Режим доступа: <https://fastapi.tiangolo.com> (дата обращения: 29.04.2026).
16. Документация aiogram 3.x. — Режим доступа: <https://docs.aiogram.dev> (дата обращения: 29.04.2026).
17. ChromaDB Documentation. — Режим доступа: <https://docs.trychroma.com> (дата обращения: 29.04.2026).
18. Mistral AI. Mistral 7B. — Режим доступа: <https://ollama.com/library/mistral> (дата обращения: 29.04.2026).
19. HuggingFace Model Card: cointegrated/rubert-tiny2. — Режим доступа: <https://huggingface.co/cointegrated/rubert-tiny2> (дата обращения: 29.04.2026).
20. Docker Documentation. — Режим доступа: <https://docs.docker.com> (дата обращения: 29.04.2026).

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09-34 PO 01-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]