

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Программная инженерия»

СОГЛАСОВАНО

Старший разработчик в X5 Tech

_____ В. Е. Козловский

«__» _____ 2026 г.

УТВЕРЖДЕНО

Академический руководитель
образовательной программы
"Программная инженерия",
старший преподаватель департамента
программной инженерии

_____ Н. А. Павлов

«__» _____ 2026 г.

**РАЗРАБОТКА ИНТЕЛЛЕКТУАЛЬНОГО АССИСТЕНТА ДЛЯ
ОБРАЗОВАТЕЛЬНЫХ УЧРЕЖДЕНИЙ.**

Техническое задание

ЛИСТ УТВЕРЖДЕНИЯ

RU.17701729.05.09 ТЗ 03-1-ЛУ

Исполнители:

Студент группы БПИ236

_____ / С. Е. Растворов /

«__» _____ 2026 г.

Подп. и дата	
Инв.№ дубл.	
Взам. инв.№	
Подп. и дата	
Инв.№ подл	

УТВЕРЖДЕН

RU.17701729.05.09 ТЗ 03-1-ЛЮ

**РАЗРАБОТКА ИНТЕЛЛЕКТУАЛЬНОГО АССИСТЕНТА ДЛЯ
ОБРАЗОВАТЕЛЬНЫХ УЧРЕЖДЕНИЙ.**

Техническое задание

RU.17701729.05.09 ТЗ 03-1

Листов 24

Инов.№ подп	Подп. и дата	Взам. инв.№	Инов.№ дубл.	Подп. и дата

АННОТАЦИЯ

Техническое задание – это основной документ, оговаривающий набор требований и порядок создания программного продукта, в соответствии с которым производится разработка программы ее тестирование и приемка.

Настоящее Техническое задание на разработку «Разработка интеллектуального ассистента для образовательных учреждений» содержит следующие разделы: «Введение», «Основания для разработки», «Назначение разработки», «Требования к программе», «Требования к программной документации», «Технико-экономические показатели», «Стадии и этапы разработки», «Порядок контроля и приемки», приложения [7].

В разделе «Введение» указано наименование и краткая характеристика области применения программы.

В разделе «Основания для разработки» указан документ, на основании которого ведется разработка, и наименование темы разработки.

В разделе «Назначение разработки» указано функциональное и эксплуатационное назначение создаваемого программного продукта.

Раздел «Требования к программе» содержит указание на основные требования к функциональным характеристикам программы, к её надежности и к условиям эксплуатации, к составу и параметрам технических средств, к информационной и программной совместимости, к маркировке и упаковке, к транспортировке и хранению, а также специальные требования.

Раздел «Требования к программным документам» содержит указание на предварительный состав программной документации и специальные требования к ней.

Раздел «Технико-экономические показатели» содержит информацию об ориентировочной экономической эффективности разработки, экономические преимущества разработки программы.

Раздел «Стадии и этапы разработки» содержит информацию о стадиях разработки, этапах и содержании работ.

В разделе «Порядок контроля и приемки» указаны общие требования к приемке работы.

Настоящий документ разработан в соответствии с требованиями:

1. ГОСТ 19.101-77 [1]: Виды программ и программных документов.
2. ГОСТ 19.102-77 [2]: Стадии разработки.
3. ГОСТ 19.103-77 [3]: Обозначения программ и программных документов.
4. ГОСТ 19.104-78 [4]: Основные надписи.
5. ГОСТ 19.105-78 [5]: Общие требования к программным документам.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

RU.17701729.05.09 ТЗ 03-1

6. ГОСТ 19.106-78 [6]: Требования к программным документам, выполненным печатным способом.

7. ГОСТ 19.201-78 [7]: Техническое задание. Требования к содержанию и оформлению.

Изменения к данному Техническому заданию оформляются согласно ГОСТ 19.603-78 [12], ГОСТ 19.604-78 [13].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	6
1.1. Наименование программы	6
1.2. Краткая характеристика области применения программы	6
2. ОСНОВАНИЯ ДЛЯ РАЗРАБОТКИ	7
2.1. Документ(ы), на основании которого(ых) ведется разработка	7
2.2. Наименование темы разработки	7
3. НАЗНАЧЕНИЕ РАЗРАБОТКИ	8
3.1. Функциональное назначение	8
3.2. Эксплуатационное назначение	8
4. ТРЕБОВАНИЯ К ПРОГРАММЕ	9
4.1. Требования к функциональным характеристикам	9
4.1.1. Требования к составу выполняемых функций	9
4.1.2. Требования к организации входных данных	9
4.1.3. Требования к организации выходных данных	10
4.1.4. Требования к временным характеристикам	10
4.1.5. Требования к интерфейсу	10
4.2. Требования к надежности	11
4.3. Условия эксплуатации	11
4.3.1. Климатические условия эксплуатации	11
4.3.2. Требования к видам обслуживания	11
4.3.3. Требования к численности и квалификации персонала	11
4.4. Требования к составу и параметрам технических средств	12
4.4.1. Программные средства	12
4.4.2. Технические средства	12
4.5. Требования к информационной и программной совместимости	12
4.5.1. Требования к информационным структурам и методам решения	12
4.5.2. Требования к программным средствам, используемым программой	12
4.5.3. Требования к исходным кодам и языкам программирования	12
4.5.4. Требования к защите информации и программы	13
4.6. Требования к маркировке и упаковке	13
4.7. Требования к транспортированию и хранению	13

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4.8. Специальные требования	13
5. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ	15
5.1. Состав программной документации	15
5.2. Специальные требования к программной документации	15
6. ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ	16
6.1. Предполагаемая потребность	16
6.2. Целевая аудитория	16
6.3. Преимущества перед аналогами	16
7. СТАДИИ И ЭТАПЫ РАЗРАБОТКИ	18
7.1. Стадии разработки, этапы и содержание работ	18
7.2. Сроки разработки и исполнители	20
8. ПОРЯДОК КОНТРОЛЯ И ПРИЕМКИ	21
8.1. Виды испытаний	21
8.2. Общие требования к приемке работы	21
СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ	22
ПРИЛОЖЕНИЕ. ССЫЛКИ НА АНАЛОГИ	23

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

1. ВВЕДЕНИЕ

1.1. Наименование программы

Наименование программы – «Разработка интеллектуального ассистента для образовательных учреждений».

Наименование программы на английском языке – «Development of an Intelligent Assistant for Educational Institutions».

1.2. Краткая характеристика области применения программы

Программа предназначена для серверной обработки вопросов студентов и преподавателей НИУ ВШЭ и других вузов. Серверная часть принимает запросы из веб-интерфейса, Telegram-бота и программного API, выполняет поиск по внутренним документам образовательной организации и формирует ответ с указанием источников. В индивидуальной части работы рассматриваются серверный API, механизм формирования ответа на основе найденных фрагментов (RAG), подготовка корпуса, векторный индекс, ограниченная память диалогов, технические метрики, обработка ошибок и защита границ доверия при обращении к генеративной модели.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

2. ОСНОВАНИЯ ДЛЯ РАЗРАБОТКИ

2.1. Документ(ы), на основании которого(ых) ведется разработка

Разработка ведется на основании учебного плана подготовки бакалавров по направлению 09.03.04 «Программная инженерия» и утвержденной академическим руководителем программы темы курсового проекта.

2.2. Наименование темы разработки

Разработка серверной части интеллектуального ассистента для образовательных учреждений с механизмом RAG, который включает загрузку документов, построение векторного индекса, поиск релевантных фрагментов, формирование ответа, серверную аутентификацию и защиту от прямого и косвенного внедрения вредоносных инструкций в запрос к генеративной модели.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

3. НАЗНАЧЕНИЕ РАЗРАБОТКИ

3.1. Функциональное назначение

- Серверный API для обработки вопросов через методы POST /ask и POST /web/ask, включая обмен данными с Telegram-ботом.
- Автоматизированная обработка вопроса по схеме RAG: нормализация вопроса, поиск релевантных фрагментов внутренней базы знаний и формирование ответа со ссылками на источники.
- Подготовка корпуса документов и построение векторного индекса Chroma на основе эмбеддингов HuggingFace.
- Серверная аутентификация, разграничение веб-ролей и изоляция ограниченного диалогового контекста разных пользователей.
- Технические метрики, обработка ошибок, резервный ответ при недоступности генеративной модели и защита недоверенного пользовательского и документного контекста.

3.2. Эксплуатационное назначение

- Запуск FastAPI-сервера, векторного хранилища и связанных баз данных в составе Docker Compose.
- Работа с локальной генеративной моделью Ollama и заранее подготовленным корпусом документов.
- Обслуживание запросов веб-интерфейса, Telegram-бота и программных серверных интеграций.
- Регламентное обновление корпуса документов и поискового индекса через служебную команду или начальную подготовку пустого хранилища.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4. ТРЕБОВАНИЯ К ПРОГРАММЕ

4.1. Требования к функциональным характеристикам

4.1.1. Требования к составу выполняемых функций

- Прием внешнего программного вопроса методом POST /ask при наличии заголовка X-API-Key; поля запроса не предоставляют вызывающей стороне управление пользовательской памятью.
- Прием вопроса методом POST /web/ask при наличии корректного X-API-Key или действующей веб-сессии; память применяется при наличии веб-пользователя, определённого сервером по защищённому идентификатору сеанса.
- Прием обращений Telegram через аутентифицированное служебное взаимодействие с ботом. Сервер формирует ключ памяти вида tg:<telegram_id> из подтверждённого идентификатора пользователя Telegram.
- Нормализация вопроса: после удаления крайних пробельных символов вопрос должен быть непустой строкой длиной не более 500 символов.
- Загрузка документов корпуса форматов PDF, HTML, HTM, TXT и DOCX, нормализация текста, разбиение на фрагменты и сохранение метаданных в ChromaDB.
- Построение векторного индекса через служебную команду или начальную подготовку пустого хранилища при запуске.
- Векторный поиск релевантных фрагментов, формирование ответа локальной моделью Ollama и возврат источников в единой структуре JSON-ответа.
- Формирование резервного ответа из найденных фрагментов при недоступности Ollama или превышении ограничения времени после успешного поиска.
- Предоставление проверки живости процесса через GET /health и технических метрик Prometheus через защищённый GET /metrics.

4.1.2. Требования к организации входных данных

- Тело запросов POST /ask и POST /web/ask в формате JSON с обязательным полем question и необязательным полем session_id. Поле session_id считается недоверенным и не используется для выбора пользовательской памяти.
- Заголовок X-API-Key для доступа к POST /ask, GET /metrics и одному из вариантов доступа к POST /web/ask.
- Защищённый идентификатор веб-сеанса web_session для определения веб-пользователя и его роли при веб-доступе.
- Подтверждённый идентификатор Telegram-пользователя, передаваемый через аутентифицированное служебное взаимодействие с ботом, для поддержки памяти Telegram-диалога.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- Документы корпуса форматов PDF, HTML, HTM, TXT и DOCX из каталога, заданного конфигурацией или аргументом служебной команды.

4.1.3. Требования к организации выходных данных

- JSON-ответы POST /ask и POST /web/ask с верхнеуровневыми полями answer, sources и metadata.
- Элементы массива sources с текстом использованного фрагмента и метаданными источника, включая название, путь, страницу, номер фрагмента и идентификаторы при наличии таких сведений.
- Объект metadata со сведениями о модели, модели эмбедингов, числе источников, служебной оценке уверенности, признаке резервного режима, причине резервного режима и длительности этапов обработки.
- JSON-ответ GET /health с состоянием живости процесса.
- Текстовые метрики Prometheus для GET /metrics, доступные только при корректном X-API-Key.
- Системные журналы запросов, отказов в доступе, ошибок векторного хранилища и переходов в резервный режим.

4.1.4. Требования к временным характеристикам

- Среднее время ответа POST /ask на контрольном наборе вопросов должно составлять не более 7 секунд при доступной локальной модели и подготовленном индексе.
- Вопросы недопустимого типа, пустые вопросы и вопросы длиннее 500 символов должны отклоняться до обращения к RAG.
- При недоступности Ollama после успешного поиска сервер должен вернуть резервный ответ без HTTP 5xx и указать признак резервного режима в metadata.
- Проверка живости /health не должна выполнять дорогие проверки зависимостей и предназначена для подтверждения работы HTTP-процесса.

4.1.5. Требования к интерфейсу

- POST /ask — программный метод обработки вопроса с обязательным X-API-Key. Внешние обращения не получают управление пользовательской памятью.
- POST /web/ask — метод обработки вопроса для веб-клиента и серверных интеграций; доступ допускается по X-API-Key или веб-сессии, роль определяется только для веб-пользователя.
- Служебное взаимодействие Telegram-бота с сервером должно проходить отдельную аутентификацию и передавать подтверждённый Telegram ID, из которого сервер самостоятельно формирует ключ памяти.
- GET /health — неаутентифицированная проверка живости HTTP-процесса.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

- GET /metrics — защищённый X-API-Key метод выдачи технических метрик Prometheus.
- Интерактивная документация API, формируемая FastAPI, используется как вспомогательный справочник для разработчика.

4.2. Требования к надежности

- Контейнеризация с использованием Docker Compose и разделение серверного API, векторного хранилища, базы веб-пользователей и базы Telegram-журнала.
- Централизованное журналирование ошибок проверки входных данных, отказов доступа, ошибок векторного хранилища, ошибок генеративной модели и сбоев пользовательской памяти.
- Ограниченная память предыдущих вопросов хранится в серверном хранилище и выбирается только по ключу, сформированному доверенным серверным кодом.
- Отказ генеративной модели после успешного поиска приводит к резервному ответу из найденных фрагментов, а отказ векторного хранилища возвращает контролируемую ошибку сервера.

4.3. Условия эксплуатации

4.3.1. Климатические условия эксплуатации

Эксплуатация в стандартных условиях офисного помещения или дата-центра без специальных требований к климату.

4.3.2. Требования к видам обслуживания

- Резервное копирование баз данных, конфигурации и векторного хранилища согласно регламенту сопровождения.
- Обновление корпуса документов и пересборка поискового индекса через служебную команду индексации.
- Наблюдение за длительностью поиска, длительностью генерации, общим временем обработки, числом ошибок и количеством резервных ответов.

4.3.3. Требования к численности и квалификации персонала

- Серверный разработчик — С. Е. Растворов: API, RAG, индексация, память, метрики, обработка ошибок, Docker-конфигурация и серверные испытания.
- Аналитик корпуса документов — А. К. Соколова: структура источников и требования к составу базы знаний.
- Разработчик интерфейсов — Л. А. Субботин: пользовательский интерфейс и сценарии взаимодействия с серверным API.
- Ответственный инженер инфраструктуры при промышленной эксплуатации: сопровождение серверного окружения и мониторинга.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4.4. Требования к составу и параметрам технических средств

4.4.1. Программные средства

- Python 3.12, FastAPI, aiogram 3.x.
- LangChain, HuggingFace Embeddings (ruBERT-tiny2), ChromaDB.
- Ollama и локальная генеративная модель Mistral.
- PostgreSQL 16, SQLAlchemy (asyncpg).
- Docker и Docker Compose; rypdf, средства чтения HTML, TXT и DOCX для подготовки корпуса документов.
- Typst для технической документации, Git для контроля версий.

4.4.2. Технические средства

- Сервер Linux x86_64: 4 vCPU, 16 GB RAM для прототипа; при использовании GPU — 1×NVIDIA 8 GB+.
- Накопитель от 20 GB (SSD предпочтительно) под БД, индексы и логи.
- Сетевое подключение от 100 Мбит/с к внутренним системам университета.

4.5. Требования к информационной и программной совместимости

4.5.1. Требования к информационным структурам и методам решения

- Поддержка источников PDF, HTML, HTM, TXT и DOCX; единый формат хранения эмбеддингов и метаданных: source, title, page, mime_type, chunk_index, char_start, char_end, document_id, chunk_id и indexed_at.
- Разбиение текста на перекрывающиеся фрагменты с сохранением идентификаторов документа и фрагмента для обратной навигации.

4.5.2. Требования к программным средствам, используемым программой

- Взаимодействие компонентов через HTTP-методы FastAPI, ChromaDB, базу веб-аутентификации и PostgreSQL-журнал Telegram-обращений; Docker Compose задаёт сеть сервисов.
- Конфигурация через .env и переменные окружения, включая ключ программного API, адрес локальной генеративной модели, пути к корпусу и векторному хранилищу, строки подключения к базам данных и служебные токены веб- и Telegram-контуров.
- Для генерации ответа требуется доступ к локальному Ollama; при его недоступности после успешного поиска формируется резервный ответ из найденных фрагментов.

4.5.3. Требования к исходным кодам и языкам программирования

- Основная разработка на Python 3.12; SQLAlchemy для работы с БД; Typst для документации.
- Инфраструктурные сценарии и Dockerfile в формате YAML/Dockerfile; системные инструкции модели и конфигурации на русском языке.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

4.5.4. Требования к защите информации и программы

- POST /ask и GET /metrics должны требовать корректный X-API-Key; POST /web/ask должен принимать корректный X-API-Key или действующую веб-сессию.
- Ключ API не задаёт роль пользователя и не является ключом пользовательской памяти. Роли применяются к веб-пользователям и административным операциям.
- Произвольное поле session_id из тела HTTP-запроса не должно позволять получить или изменить историю другого пользователя; доверенным считается только идентификатор, сформированный серверным кодом поддерживаемого канала.
- Для Telegram требуется серверное формирование ключа памяти на основе подтверждённого Telegram ID, полученного через доверенный контур бота.
- Вопрос пользователя, история диалога и найденные фрагменты документов считаются недоверенными данными. Сервер отделяет их от доверенных системных инструкций модели.
- Пользовательские и документные данные не должны интерпретироваться как команды более высокого приоритета, менять правила доступа, раскрывать служебные инструкции или расширять доступный корпус.
- Аутентификация, авторизация, выбор корпуса документов и выбор ключа пользовательской памяти выполняются программным кодом и не делегируются генеративной модели.
- Секреты, ключи, служебная конфигурация и закрытые системные инструкции не передаются в модель и не записываются в открытые журналы.
- Размер вопроса, истории, числа найденных фрагментов и суммарного контекста модели должен быть ограничен серверной конфигурацией.
- Ответ генеративной модели должен проверяться по ожидаемой структуре и безопасно экранироваться перед отображением в веб-интерфейсе и Telegram.

4.6. Требования к маркировке и упаковке

Поставка серверной части выполняется в электронном виде: Git-репозиторий, контейнерные образы, конфигурационные примеры и комплект программной документации. Версии фиксируются тегами и журналом изменений.

4.7. Требования к транспортированию и хранению

Физическое транспортирование не требуется; хранение осуществляется через резервные копии баз данных и векторных индексов на защищённых носителях с проверкой контрольных сумм.

4.8. Специальные требования

- Возможность локального развертывания серверной части с использованием Ollama без обращения к внешним генеративным сервисам.
- Настраиваемый набор документов, параметров поиска, шаблонов системных инструкций и ограничений контекста модели.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

RU.17701729.05.09 ТЗ 03-1

- Обязательная поддержка безопасной памяти Telegram-диалога на основе подтверждённого сервером Telegram ID.
- Обязательная защита от прямого внедрения вредоносных инструкций во входном вопросе, косвенного внедрения инструкций из документа, извлечения служебных инструкций, отравления истории и доступа к источникам другого пользователя.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

5. ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

5.1. Состав программной документации

1. «Разработка интеллектуального ассистента для образовательных учреждений». Техническое задание (ГОСТ 19.201-78 [7]).
2. «Разработка интеллектуального ассистента для образовательных учреждений». Пояснительная записка (ГОСТ 19.404-79 [10]).
3. «Разработка интеллектуального ассистента для образовательных учреждений». Программа и методика испытаний (ГОСТ 19.301-79 [8]).
4. «Разработка интеллектуального ассистента для образовательных учреждений». Текст программы (ГОСТ 19.401-78 [9]).
5. «Разработка интеллектуального ассистента для образовательных учреждений». Руководство оператора (ГОСТ 19.505-79 [11]).

5.2. Специальные требования к программной документации

Подготовить инструкции по сборке контейнерных образов, шаблоны .env, примеры запросов к API, описание формата ответа, правила обновления корпуса документов, порядок запуска индексации и сценарии первичного развертывания серверной части.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

6. ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

6.1. Предполагаемая потребность

Серверная часть рассчитана на пилотную эксплуатацию в составе прототипа интеллектуального ассистента. Дальнейшее масштабирование должно выполняться за счет увеличения ресурсов API, векторного хранилища и узла генеративной модели.

6.2. Целевая аудитория

- Студенты (бакалавриат и магистратура).
- Преподаватели и учебные офисы.
- ИТ-службы и методисты для быстрых справок по регламентам.

6.3. Преимущества перед аналогами

- Ответы формируются на основе внутреннего корпуса документов образовательной организации.
- Структура JSON-ответа содержит текст ответа, перечень источников и служебные метаданные обработки.
- Локальное развертывание внутри инфраструктуры университета.
- Серверная изоляция пользовательской памяти и явные границы доверия для генеративной модели.
- Контейнерная поставка и воспроизводимая серверная инфраструктура.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Функция	Целевой ассистент	Поиск по сайту вуза (FAQ)	Универсальная генеративная модель без корпуса
Работа с внутренними документами	+	+	-
Прозрачные ссылки на источники	+	+	-
Диалоговый режим и история	+	-	+
Локальное развертывание	+	-	-
Серверная изоляция памяти и защита границ доверия	+	-	-
Итого	5	2	1

Таблица 1. Сравнение функциональных характеристик

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

7. СТАДИИ И ЭТАПЫ РАЗРАБОТКИ**7.1. Стадии разработки, этапы и содержание работ**

Стадии и этапы разработки определены с учетом ГОСТ 19.102-77 [2].

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

Стадия разработки	Этап работ	Содержание работ	Сроки выполнения
Техническое задание	Проработка предметной области и требований	Определение источников данных и пользовательских сценариев	1.11.25 – 10.12.25
	Согласование ТЗ	Утверждение состава серверных функций и технических метрик	10.12.25 – 16.12.25
Разработка прототипа	Подготовка данных	Загрузка документов PDF, HTML, HTM, TXT и DOCX, нормализация текста и формирование метаданных	01.01.26 – 10.03.26
	Векторное хранилище	Построение и валидация индекса Chroma на корпусе документов	01.01.26 – 24.02.26
	Генеративная модель и правила обращения	Настройка Ollama, системных инструкций, ограничений контекста и резервного ответа	01.01.26 – 24.02.26
	Серверные интерфейсы	Интеграция Telegram-бота и веб-интерфейса с серверным API, авторизация, память и журналирование	25.02.26 – 25.03.26
Испытания и приемка	Функциональные и нагрузочные испытания	Прогон сценариев, замер времени ответа и устойчивости	25.02.26 – 15.03.26
	Пилотная группа	Пилотное тестирование, сбор и анализ обратной связи	01.04.26 – 16.04.26
	Документация и сдача	Актуализация серверных инструкций, развертывание на тестовом сервере, отчетность	16.04.26 – 25.04.26

Таблица 2. Стадии и этапы разработки

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

7.2. Сроки разработки и исполнители

- Сбор, очистка и структурирование данных университета — А. К. Соколова.
- Разработка и настройка серверного ядра системы: векторная база данных, метод RAG, генеративная модель, программный API, память и метрики — С. Е. Растворов.
- Создание пользовательских интерфейсов и организация тестирования с реальными пользователями — Л. А. Субботин.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

8. ПОРЯДОК КОНТРОЛЯ И ПРИЕМКИ

Контроль и приемка разработки осуществляются в соответствии с документом «Программа и методика испытаний» (ГОСТ 19.301–79 [8]).

8.1. Виды испытаний

- Функциональные испытания серверной обработки вопросов по схеме RAG на контрольном наборе вопросов и ответов из учебных регламентов.
- Интеграционные испытания методов POST /ask, POST /web/ask, GET /health и GET /metrics с проверкой кодов ответа и структуры JSON-ответа.
- Испытания загрузки документов PDF, HTML, HTM, TXT и DOCX, разбиения на фрагменты и сохранения метаданных.
- Испытания изоляции памяти веб-пользователей и целевой памяти Telegram-пользователей.
- Отрицательные испытания прямого внедрения вредоносных инструкций во входном вопросе, косвенного внедрения инструкций из документа, извлечения служебных инструкций, отравления истории и доступа к источникам другого пользователя.
- Нагрузочные испытания серверного API с замером времени ответа и устойчивости.

8.2. Общие требования к приемке работы

- Не менее 85% контрольных вопросов отвечены корректно по внутренним документам.
- Среднее время ответа POST /ask не превышает 7 секунд при доступной локальной модели и подготовленном индексе.
- Недопустимые вопросы отклоняются кодом HTTP 400 до обращения к RAG.
- Защищённые методы отклоняют запросы без действующих учётных данных.
- Резервный ответ при недоступности Ollama содержит сведения из найденных фрагментов и признак резервного режима в metadata.
- Память веб- и Telegram-пользователей изолирована. Произвольный session_id из клиентского тела запроса не даёт доступа к чужой истории.
- Испытания защиты от внедрения вредоносных инструкций подтверждают сохранность системных правил, ограничений доступа и состава доступных источников. Недоверенный вопрос, история и документный текст не приводят к раскрытию секретов или служебных инструкций.
- Отсутствуют дефекты, препятствующие выполнению обязательных серверных функций, нарушающие безопасность данных или приводящие к смешению пользовательских контекстов.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

СПИСОК ИСПОЛЬЗУЕМОЙ ЛИТЕРАТУРЫ

1. ГОСТ 19.101-77: Виды программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
2. ГОСТ 19.102-77: Стадии разработки. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
3. ГОСТ 19.103-77: Обозначения программ и программных документов. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
4. ГОСТ 19.104-78: Основные надписи. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
5. ГОСТ 19.105-78: Общие требования к программным документам. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
6. ГОСТ 19.106-78: Требования к программным документам, выполненным печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
7. ГОСТ 19.201-78: Техническое задание. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
8. ГОСТ 19.301-79: Программа и методика испытаний. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
9. ГОСТ 19.401-78: Текст программы. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
10. ГОСТ 19.404-79: Пояснительная записка. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
11. ГОСТ 19.505-79: Руководство оператора. Требования к содержанию и оформлению. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
12. ГОСТ 19.603-78: Общие правила внесения изменений. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.
13. ГОСТ 19.604-78: Правила внесения изменений в программные документы, выполненные печатным способом. // Единая система программной документации. – М.: ИПК Издательство стандартов, 2001.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ПРИЛОЖЕНИЕ. ССЫЛКИ НА АНАЛОГИ

Приложение	Ссылка
Официальные ответы НИУ ВШЭ (FAQ)	https://www.hse.ru/answers
ChatGPT	https://chat.openai.com
YandexGPT	https://ya.ru/ai/gpt

Дата обращения: 12.02.25.

Изм.	Лист	№ докум.	Подп.	Дата
RU.17701729.05.09 ТЗ 03-1				
Инв. № подл.	Подп. и дата	Взам. Инв. №	Инв. № дубл.	Подп. и дата

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

[illegible]